MAKALE SUNUMU

Deep Learning ile Büyük Veri İçin Tahmin Modelleri

Hazırlayan : Halil İbrahim Dürmüş

İçindekiler

1. Yönetici Özeti3

2. Makale Hakkında Genel Bilgi3

3. Sinir Ağlarının Tarihsel Gelişimi4

4. Yapay Sinir Ağı Mimarileri5

5. Deep Feedforward Neural Networks (D-FFNN)7

6. Convolutional Neural Networks (CNN)8

7. Deep Belief Networks (DBN)11

8. Autoencoders (AE)13

9. Long Short-Term Memory (LSTM)14

10. Tartışma ve Değerlendirme16

11. Sonuç ve Çıkarımlar18

12. Referanslar & Ek Kaynaklar19

1. Yönetici Özeti

Bu makale, 2020 yılında Frontiers in Artificial Intelligence dergisinde yayımlanan, deep learning modellerine giriş niteliğinde kapsamlı bir inceleme makalesidir. Temel hedef: Disiplinlerarası araştırmacılar için D-FFNN, CNN, DBN, AE ve LSTM mimarilerini teknik detaylarıyla açıklamak ve bu modelleri uygulamaya hazır hale getirmek.

Makale, yapay zeka ve makine öğrenmesi alanındaki en temel beş derin öğrenme mimarisini sistematik biçimde ele almaktadır. Her mimari için matematiksel temeller, öğrenme algoritmaları, varyantlar ve uygulama alanları kapsamlı şekilde incelenmektedir.

Temel Bulgular

- Deep learning, karmaşık tahmin modelleri öğrenmek için kullanılan bir algoritma ailesidir
- CNN'ler bilgisayarla görme görevlerinde baskın model konumundadır
- LSTM'ler sıralı veri (metin, ses, video) analizinde üstün performans göstermektedir
- DBN'ler, denetimsiz ön-eğitim ile denetimli ince ayarı birleştirir
- Otokodlayıcılar boyut azaltma ve temsil öğrenmede etkilidir
- 25.000'den fazla eğitim örneği olmadan derin öğrenme modelleri güvenilir performans sergileyemez

2. Makale Hakkında Genel Bilgi

Alan	Bilgi
Başlık	An Introductory Review of Deep Learning for Prediction Models With Big Data
Yazarlar	Emmert-Streib F., Yang Z., Feng H., Tripathi S., Dehmer M.
Dergi	Frontiers in Artificial Intelligence
Yayın Yılı	2020
DOI	10.3389/frai.2020.00004
Makale Türü	Gözden Geçirme (Review)
Kapsam	D-FFNN, CNN, DBN, Autoencoder, LSTM — 5 temel mimari
Hedef Kitle	Disiplinlerarası veri bilimciler ve araştırmacılar

Makalenin Motivasyonu

Büyük veri çağında tüm bilim ve endüstri dalları büyük miktarda veri üretmektedir. Mevcut derin öğrenme incelemelerinin çoğu ya çok yüzeysel bir bakış açısı sunmakta ya da belirli alt konulara odaklanmaktadır. Bu makale, disiplinlerarası bilimcilerin teknik detaylara ulaşmasını kolaylaştırmak amacıyla ara düzeyde, teknik bir sunum yapmayı hedeflemektedir.

Derin öğrenme modellerinin 'Lego benzeri' yapısı, temel mimari bileşenlerden sonsuz sayıda yeni model inşa etmeye olanak tanımaktadır. Bu nedenle temel blokların anlaşılması, gelecekteki YZ gelişmelerine hazırlıklı olmak için kritik öneme sahiptir.

3. Sinir Ağlarının Tarihsel Gelişimi

Yapay sinir ağlarının tarihçesi oldukça uzundur. Makale, en önemli dönüm noktalarını kronolojik bir zaman çizelgesi şeklinde sunmaktadır:

Yıl	Gelişme	Önemi
1943	McCulloch-Pitts Nöronu	İlk matematiksel nöron modeli — öğrenme içermez
1949	Hebbian Öğrenme	Biyolojik motivasyonlu ilk denetimsiz öğrenme
1957	Perceptron (Rosenblatt)	Tek katmanlı doğrusal ikili sınıflandırıcı
1960	Delta Öğrenme Kuralı	Gradyan iniş tabanlı ağırlık güncellemesi
1968	GMDH Ağları	İlk derin öğrenme ağı olarak kabul edilir (8 katman)
1969	Minsky & Papert	XOR problemi — 'YZ Kışı'nı tetikledi
1974	Backpropagation	Werbos tarafından önerildi, denetimli öğrenmeyi mümkün
1980	Neocognitron	İlk CNN mimarisi — görsel örüntü tanıma
1982	Hopfield Ağı	İçerik-adreslenebilir bellek, tekrarlayan ağ örneği
1986	BP Yeniden Doğuşu	Rumelhart et al. — faydalı iç temsiller gösterildi
1989	LeNet (LeCun)	El yazısı rakamlar için CNN + backpropagation
1991	Vanishing Gradient	Hochreiter — derin ağlarda kaybolan/patlayan gradyan
1997	LSTM	Hochreiter & Schmidhuber — uzun vadeli bağımlılık sorunu çözüldü
2006	Deep Belief Networks	Hinton — katman bazlı ön-eğitim ile derin ağlar mümkün
2012	AlexNet	Krizhevsky — ImageNet yarışmasını kazandı; CNN rönesansı başladı
2014	GAN	Goodfellow — 'son 20 yılın en harika fikri'
2019	Turing Ödülü	Bengio, Hinton, LeCun — derin öğrenmenin mucitleri

Yayın istatistiklerine göre, Web of Science veritabanında derin öğrenme ile ilgili toplam 30.230 yayın bulunmaktadır. Bu yayınların %52.1'i bilgisayar bilimlerinde, %41.5'i mühendislik alanında yer almaktadır. Uygulama alanlarında tıbbi görüntüleme (%6.2), robotik (%2.6) ve hesaplamalı biyoloji (%2.5) en fazla ilgi gören alanlardır.

4. Yapay Sinir Ağı Mimarileri

4.1 Yapay Nöron Modeli

Her sinir ağının temel birimi yapay nöron modelidir. Bir nöronun matematiksel formülasyonu şöyle tanımlanır:

Girdi: $x \in R^n$ | Ağırlık: $w \in R^n$ | Bias: b (skaler)

$z = w^T x + b$ (doğrusal kombinasyon)

$y = \varphi(z) = \varphi(w^T x + b)$ (aktivasyon fonksiyonu uygulanır)

φ: Aktivasyon fonksiyonu — doğrusal olmayan dönüşüm sağlar

4.2 Aktivasyon Fonksiyonları

Fonksiyon	Formül	Çıkış Aralığı	Kullanım Alanı
Sigmoid	$\sigma(x) = 1/(1+e^{-x})$	(0, 1)	Olasılık çıkışları, eski ağlar
Tanh	$\tanh(x) = (e^x-e^{-x})/(e^x+e^{-x})$	(-1, 1)	Gizli katmanlar
ReLU	$R(x) = \max(0, x)$	$[0, \infty)$	Derin ağlar — en popüler seçim
Heaviside	$H(x) = 0$ veya 1	[0, 1]	Perceptron modeli
Softmax	$y_i = e^{x_i} / \Sigma e^{x_j}$	(0, 1)	Çok sınıflı çıkış katmanı

4.3 Temel Ağ Tipleri Karşılaştırması

Ağ Tipi	Bağlantı Yapısı	Döngü	Tipik Kullanım
Feedforward (FFNN)	İleriye doğru tek yönlü	Yok	Genel sınıflandırma ve regresyon
Recurrent (RNN)	Döngüsel bağlantılar	Var	Sıralı veri, zaman serileri
Convolutional (CNN)	Yerel bağlantı + paylaşımlı ağırlık	Yok	Görüntü, ses, metin
Hopfield Network	Tam bağlantılı FRN	Yok (DAG)	İçerik-adreslenebilir bellek
Boltzmann Machine	Çift yönlü, olasılıksal	Var	Üretici model, özellik öğrenme

5. Deep Feedforward Neural Networks (D-FFNN)

5.1 Temel Kavramlar

Derin Feedforward Sinir Ağı (D-FFNN), aynı zamanda Multilayer Perceptron (MLP) olarak da bilinir. İkiden fazla gizli katmana sahip FFNN'ler derin mimari olarak kabul edilmektedir.

Evrensel Yaklaşım Teoremi (Hornik, 1991):

Bir gizli katmana ve sınırlı sayıda nörona sahip bir FFNN, R^n üzerindeki her sürekli fonksiyonu yaklaşık olarak ifade edebilir. Ancak bu teoreme göre nasıl öğrenileceği bilinmemektedir — bu nedenle derin ağlar (D-FFNN) pratikte tercih edilmektedir.

5.2 Matematiksel Formülasyon

D-FFNN'nin çıktısı, iç içe geçmiş aktivasyon fonksiyonları ile ifade edilir:

$$f(x) = \varphi^{(2)}(W^{(2)}\varphi^{(1)}(W^{(1)}x + b^{(1)}) + b^{(2)})$$

Çok katmanlı form: $\varphi = \varphi^{(n)}(\ldots \varphi^{(2)}(\varphi^{(1)}(x)) \ldots)$

Öğrenme: Stochastic Gradient Descent (SGD) + Backpropagation

5.3 Neden Derin Ağlar?

- Sığ ağlarda (1 gizli katman) gizli nöron sayısı üstel büyüyebilir
- Derin ağlar aynı kapasiteyi çok daha az parametreyle temsil edebilir
- Her katman önceki katmanın özelliklerini daha soyut düzeyde öğrenir
- Pratikte: 3+ gizli katman 'derin' olarak kabul edilir

5.4 Uygulama Alanları

- İlaç toksisitesi tahmini (DeepTox — Mayr et al., 2016)
- İlaç-hedef etkileşimi tahmini
- Tablo/yapılandırılmamış veri analizi

6. Convolutional Neural Networks (CNN)

CNN, evrişim (convolution), ReLU ve havuzlama (pooling) katmanlarını kullanan özel bir Feedforward Sinir Ağıdır. Görüntü ve sinyal işlemede baskın mimari haline gelmiştir.

6.1 CNN'in Temel Avantajları

Geleneksel ANN'lerden Farkı:

- Tam bağlantı yerine YEREL bağlantı — parametre sayısını dramatik azaltır
- PAYLAŞIMLI AĞIRLIKLAR (kernel) — özellik tespitçiler tüm lokasyonlarda çalışır
- Bu iki özellik birlikte yüksek boyutlu verileri (görüntüler) verimli işler

6.2 Temel Bileşenler

6.2.1 Evrişim Katmanı (Convolutional Layer)

Kernel adı verilen bir filtre, girdi üzerinde kayarak her yerel bölge ile iç çarpım yapar ve aktivasyon haritası oluşturur. Çıktı boyutu üç hiperparametre tarafından belirlenir:

Hiperparametre	Açıklama	Etkisi
N — Kernel Boyutu	Filtre penceresi: N×N piksel	Daha büyük N → daha geniş alıcı alan
S — Stride	Kernelin kaç piksel kaydığı	Büyük S → küçük aktivasyon haritası
P — Zero-Padding	Sınıra eklenen sıfır sayısı	Boyut koruma için kullanılır

Çıkış boyutu hesabı:

$$W_{çıkış} = (W_{giriş} - N + 2P) / S + 1$$

$$H_{çıkış} = (H_{giriş} - N + 2P) / S + 1$$

Örnek: 100×100×3 girdi, 4×4×3 kernel, 2 kernel, 100 nöron → sadece 96 parametre

(Tam bağlantılı olsaydı: 100 × 100 × 3 × 100 = 3.000.000 parametre)

6.2.2 Havuzlama Katmanı (Pooling Layer)

Girdi boyutunu azaltarak uzamsal değişmezlik kazandırır ve aşırı öğrenmeyi önlemeye yardımcı olur. En yaygın yöntem Max-Pooling'dir; $A_{i,j,k} = \max(R_{i-n:i+n,\ j-n:j+n,\ k})$.

- Max-Pooling: Penceredeki maksimum değeri alır — görüntü işlemede en üstün
- Average-Pooling: Ortalama değeri alır
- Stride=2, window=2 ile girdi boyutunu yarıya indirir

6.2.3 Tam Bağlantılı Katman (Fully-Connected Layer)

Geleneksel CNN mimarilerinde, son katmanlardan önce çıkış katmanına doğrusal olmayan ilişkileri modellemek için eklenir. Ancak overfitting riskini artırdığından modern mimarilerde max-over-time pooling gibi alternatiflerle değiştirme eğilimi vardır.

6.3 Önemli CNN Varyantları

Model	Yıl	Katman Sayısı	Temel Yenilik	Sonuç
AlexNet	2012	8	GPU kullanımı + ReLU + Dropout	ImageNet 2012 kazananı
VGGNet (VGG19)	2014	19	Sadece 3×3 konv. katmanlar	Top-5 hata: %8.0
GoogLeNet	2014	22	Inception bloğu — seyrek yapı	ILSVRC2014 kazananı
ResNet	2016	152	Artık bağlantılar (residual)	ILSVRC2016 — hata: %3.57

6.4 Inception Bloğu Konsepti

GoogLeNet'in temel yeniliği olan Inception bloğu, ağı mümkün olduğunca seyrek tutarken hızlı matris hesaplamalarından yararlanır. Birden fazla paralel konvolüsyon boyutu (1×1, 3×3, 5×5) eş zamanlı çalıştırılır ve sonuçlar birleştirilir. Bu, farklı ölçeklerdeki özellikleri tek bir adımda çıkarmaya olanak tanır.

6.5 ResNet ve Degradasyon Problemi

ResNet, katman derinliği arttıkça oluşan 'bozunma problemi'ni (degradation) çözmek için geliştirilmiştir. Gradyan kaybından farklı olan bu sorun, optimizasyonun lokal minimumlara takılmasından kaynaklanmaktadır.

Artık Öğrenme (Residual Learning) Formülasyonu:

Klasik yaklaşım: $H(x)$ — doğrudan hedef eşlemeyi öğren

ResNet yaklaşımı: $F(x) = H(x) - x$ — artık eşlemeyi öğren

Yeniden formüle: $H(x) = F(x) + x$

Shortcut bağlantıları ile sıfır artık öğrenilirse katman en azından

sığ ağdan daha kötü sonuç vermez (kimlik eşlemesi garantisi).

7. Deep Belief Networks (DBN)

DBN, Restricted Boltzmann Machine (RBM) ile Deep Feedforward Neural Network'ü birleştiren hibrit bir modeldir. RBM'ler giriş katmanını oluştururken D-FFNN'ler çıkış katmanını oluşturur.

DBN Eğitimi İki Aşamada Gerçekleşir:

Aşama 1 — Ön-Eğitim (Denetimsiz): RBM'lerin greedy katman-bazlı eğitimi

Her RBM'nin gizli katmanı, bir sonraki RBM'nin görünür katmanı olur

Aşama 2 — İnce Ayar (Denetimli): Etiket bilgisi kullanılarak backpropagation

ile parametreler optimize edilir

7.1 Restricted Boltzmann Machine (RBM)

RBM, olasılıksal aktivasyon fonksiyonu kullanan bir Boltzmann Machine'in kısıtlı halidir. Aynı katmandaki nöronlar arasında bağlantı yoktur; sadece görünür (visible) ve gizli (hidden) katmanlar arasında çift yönlü bağlantı bulunur.

RBM Enerji Fonksiyonu:

$$E(v,h) = -\Sigma_i a_i v_i - \Sigma_j b_j h_j - \Sigma_i \Sigma_j v_i h_j w_{i,j}$$

Koşullu olasılıklar:

$p(H_j=1|v) = \sigma(\Sigma_i w_{ij} v_i + b_j)$ [gizliden görünüre]

$p(V_i=1|h) = \sigma(\Sigma_j w_{ij} h_j + a_i)$ [görünüden gizliye]

7.2 Contrastive Divergence (CD) Algoritması

CD algoritması, gradyanın etkin şekilde yaklaşık hesaplanması için Gibbs örneklemesini kullanır. Koşullu dağılımlardan örnekler çekerek bir Markov zinciri oluşturur. k=1 iterasyon bile ön-eğitim için tatmin edici yaklaşım sağlayabilir (Carreira-Perpinan & Hinton, 2005).

7.3 Backpropagation ile İnce Ayar

İnce ayar aşamasında, Stochastic Gradient Descent (SGD) ile hata fonksiyonu minimize edilir. Parametre güncellemesi şu formülle gerçekleşir:

$$\theta^{(t+1)} = \theta^{(t)} - \eta\, \partial E/\partial\theta^{(t)} - \lambda\theta^{(t)} + v\, \Delta\theta^{(t-1)}$$

η = Öğrenme oranı

λ = Ağırlık bozunması (regularization)

v = Momentum (öğrenme hızlandırma ve osilayon önleme)

7.4 DBN Uygulama Alanları

Uygulama Alanı	Örnek Çalışma
Doğal Dil İşleme	Sarikaya et al., 2014 — dil anlama
Akustik Modelleme	Mohamed et al., 2011 — konuşma tanıma
Görüntü Tanıma	Hinton et al., 2006
Genomik / Biyoloji	Zhang et al., 2015 — RNA bağlama proteini
Gen Ekspresyonu Sınıflandırma	Smolander et al., 2019 — karmaşık hastalıklar

8. Autoencoders (AE)

Autoencoder, temsil öğrenmesi için kullanılan denetimsiz bir sinir ağı modelidir. Giriş ve çıkış katmanlarının boyutu eşittir; ortada daha dar bir 'kod katmanı' bulunur.

Temel İlke:

Giriş: $x \rightarrow$ Kodlama: $c = h(x) \rightarrow$ Çıkış: $y = g(c) \approx x$

Amaç: Girdiyi daha düşük boyutlu bir temsile sıkıştırmak (c),

ardından bu temsili kullanarak orijinal girdiyi yeniden oluşturmak.

Etiket kullanılmaz → Tamamen denetimsiz öğrenme

8.1 Autoencoder Mimarisi

Yapı DBN ile benzerlik gösterir. Orijinal implementasyonda (Hinton & Salakhutdinov, 2006) ağın ilk yarısı RBM ile ön-eğitime tabi tutulur, sonra 'unrolling' ile ikinci yarı oluşturulur:

- Encoder: Girdiyi aşamalı olarak düşük boyutlu temsile sıkıştırır
- Kod Katmanı (Bottleneck): En düşük boyutlu temsil — öğrenilen özellikler burada
- Decoder: Kodu yeniden orijinal boyuta genişletir

8.2 PCA ile Karşılaştırma

Özellik	PCA	Autoencoder
Dönüşüm Türü	Doğrusal (lineer)	Doğrusal olmayan (non-lineer)
Performans	Sınırlı karmaşık veriler için	Yeterli veri ile üstün
Öğrenme	Analitik (SVD)	Gradient descent ile
Yorumlanabilirlik	Yüksek (özdeğerler/özvektörler)	Düşük (kara kutu)

8.3 Autoencoder Varyantları

Varyant	Farkı	Uygulama
Sparse AE	Gizli nöronların çoğunluğu sıfır olacak şekilde regularize edilir	Özellik seçimi
Denoising AE (dAE)	Gürültülü giriş verilir, temiz çıkış beklenir	Gürültü giderme, sağlam temsil
Variational AE (VAE)	Latent uzayda dağılım öğrenir (tek nokta değil)	Üretici model, yeni veri üretimi
Stacked AE (SdAE)	Birden fazla AE üst üste yığılır	Daha derin temsil öğrenimi

9. Long Short-Term Memory (LSTM)

LSTM, Hochreiter ve Schmidhuber tarafından 1997 yılında tanıtılmıştır. Standart RNN'lerin uzun vadeli bağımlılık problemini ve kaybolan/patlayan gradyan sorununu çözen bir RNN varyantıdır.

RNN'nin Sorunu vs. LSTM'nin Çözümü:

RNN: Uzun zaman serilerinde sinyaller ya sıfıra yakınsar (vanishing) ya da patlar (exploding)

LSTM: 'Constant Error Carousel' (CEC) mekanizması bu sorunu çözer.

- Hücre durumu (cell state) uzun vadeli hafızayı korur.
- Üç kapı (gate) bilgi akışını kontrol eder.

9.1 LSTM Hücre Yapısı

Her LSTM birimi bir hücre ve üç kapıdan oluşur: giriş kapısı, çıkış kapısı ve unutma kapısı.

Bileşen	Fonksiyon	Formül
Giriş Kapısı (i^t)	Hücreye bilgi akışını kontrol eder (0=engelle, 1=geçir)	$i^t = \sigma(W^{(ix)}x^{(t)} + U^{(ih)}h^{(t-1)} + b^i)$
Hücre Girişi (l^t)	Yeni bilgiyi -1 ile 1 arasına sıkıştırır (tanh)	$l^t = \tanh(W^{(lx)}x^{(t)} + U^{(lh)}h^{(t-1)} + b^l)$
Unutma Kapısı (f^t)	Eski hücre durumundan ne unutulacağını belirler	$f^t = \sigma(W^{(fx)}x^{(t)} + U^{(fh)}h^{(t-1)} + b^f)$
Hücre Durumu (c^t)	Uzun vadeli hafıza — CEC üzerinde taşınır	$c^t = f^t \circ c^{t-1} + i^t \circ l^t$
Çıkış Kapısı (o^t)	Hücre durumundan çıkışa bilgi akışı	$o^t = \sigma(W^{(ox)}x^{(t)} + U^{(oh)}h^{(t-1)} + b^o)$
Gizli Durum (h^t)	Ağın çıktısı / kısa vadeli hafıza	$h^t = o^t \circ \tanh(c^t)$

9.2 Peephole LSTM

Gers ve Schmidhuber (2000) tarafından önerilmiştir. Standart LSTM'den farkı: kapılar $h^{(t-1)}$ yerine hücre durumu c^{t-1} kullanır. Bu, çıkış kapısının kapalı olduğu durumlarda tarihsel bilginin kaybolmasını önler.

9.3 LSTM Varyantları

Varyant	Yıl	Temel Fark
Standart LSTM + Forget Gate	1999	Hücre hafızasını sıfırlayabilen unutma kapısı eklendi
Peephole LSTM	2000	Kapılar h yerine c kullanır — eksiksiz tarih erişimi
Bidirectional LSTM (BLSTM)	2005	Hem ileri hem geri yönde bağlam erişimi
Gated Recurrent Unit (GRU)	2014	LSTM'in basitleştirilmiş versiyonu — daha az parametre
ConvLSTM	2015	Evrişimsel + LSTM — uzamsal-zamansal tahmin

9.4 LSTM Uygulama Alanları

- Metin üretimi ve sınıflandırması
- Dil çevirisi (sequence-to-sequence modeller)
- Görüntü altyazısı oluşturma
- Konuşma tanıma ve akustik modelleme
- Tıbbi kayıtlardan tahmin (DeepCare — Pham et al., 2016)
- İlaç-ilaç etkileşimi tespiti (Sahu & Anand, 2018)

10. Tartışma ve Değerlendirme

10.1 Derin Öğrenmenin Ortak Özellikleri

Tüm derin öğrenme modellerinin paylaştığı iki temel özellik bulunmaktadır:

- Temsil Öğrenme (Representation Learning): Ham veriye kıyasla daha iyi ve daha soyut temsiller öğrenilir. Her katman bir öncekinin özelliklerini daha soyut düzeyde işler.
- Doğrusal Olmayan Dönüşümler: Katmanlar arası dönüşümler doğrusal değildir; bu durum modelin ifade gücünü artırır. Temsiller manuel olarak tasarlanmaz, eğitim verisiyle öğrenilir.

10.2 Model Seçimi: Hangi Mimari Ne Zaman?

Model	En İyi Olduğu Alan	Neden?
CNN	Görüntü, video, ses, metin (yerel örüntüler)	Yerel bağlantı + paylaşımlı ağırlık çok boyutlu veriyi verimli işler
LSTM / RNN	Sıralı veri, zaman serileri, NLP	Döngüsel bağlantılar zamansal dinamikleri modellemesine olanak tanır
D-FFNN	Yapılandırılmış tablo verisi, ilaç tahminleri	Esnek, genel amaçlı — yeterli veri ile her alanda güçlü
DBN	Genomik, ses, NLP (etiketli veri az ise)	Denetimsiz ön-eğitim az etiketli veriden fayda sağlar
Autoencoder	Boyut azaltma, anomali tespiti, gürültü giderme	Etiketsiz öğrenme — temsil ve sıkıştırma

10.3 Yorumlanabilir YZ (XAI) Sorunu

Makalede ele alınan tüm modeller kara kutu tahmin modelleridir; yorumlanabilir bir yapı sunmazlar. Klinik ve tıbbi alanlarda yorumlanabilir kararlar kritik önem taşımaktadır. Açıklanabilir YZ (XAI) alanı henüz erken aşamadadır; ancak genel derin öğrenme modellerinin anlamlı yorumları bulunabilseydi bu alanı devrimleştireceği vurgulanmaktadır.

10.4 Büyük Veri vs. Küçük Veri — Kritik Bulgu

EMNIST Deneyi (10 sınıf el yazısı rakam sınıflandırma — LSTM):

Model: 4 katmanlı LSTM (3 gizli katman × 200 nöron + FC katman), batch=100

Sonuç: %5 hata eşiğinin altına inebilmek için 25.000'den fazla eğitim örneği gerekmektedir.

Çıkarım: Bu basit 10 sınıflı problem bile binlerce örnek gerektirir. Kanser tanısı gibi karmaşık problemler için veri ihtiyacı çok daha yüksektir. Derin öğrenme mucizeler yaratamaz — veri miktarı yetersizse model çöker.

10.5 İleri Düzey Modeller

Model	Temel Açıklama	Uygulama
Deep Reinforcement Learning	DL + Pekiştirmeli Öğrenme	Robotik, oyunlar, sağlık
Graph CNN	Graf yapılarındaki veriler için CNN	NLP, genomik, öneri sistemleri
Variational AE (VAE)	Dağılım öğrenen regularize AE	Görüntü/metin üretimi
GAN	İki ağın rekabeti — üretici model	Görüntü sentezi, veri artırma

11. Sonuç ve Çıkarımlar

11.1 Makalenin Temel Mesajları

- Derin öğrenme, büyük veri çağının en güçlü araçlarından biridir ve birçok alanda son teknoloji başarılar elde etmektedir
- Beş temel mimari (D-FFNN, CNN, DBN, AE, LSTM) pratik uygulamaların büyük çoğunluğunu kapsamaktadır
- Bu mimariler, 'Lego bloğu' gibi kombinasyonlarla yeni, özel mimariler oluşturmak için kullanılabilir
- Veri miktarı kritik önem taşır: az veriyle derin öğrenme güvenilir sonuçlar vermez
- Model ve veri kombinasyonu her zaman bağlam-spesifik değerlendirilmelidir
- XAI (Açıklanabilir YZ) henüz erken aşamada olup klinik uygulamalar için kritik bir ihtiyaçtır

11.2 Pratik Uygulama Rehberi

Sorun Türü	Önerilen Model	Dikkat Edilecek Husus

Görüntü sınıflandırma/ tanıma	CNN (ResNet, EfficientNet)	Veri artırma, transfer öğrenmeden yararlan
Metin / Dil işleme	LSTM, Transformer, CNN	Word embedding seç (word2vec/GloVe/ FastText)
Zaman serisi tahmini	LSTM, GRU, ConvLSTM	Sekans uzunluğuna ve veri miktarına dikkat
Boyut azaltma / Anomali	Autoencoder (VAE)	Bottleneck boyutunu dikkatli ayarla
Az etiketli veri	DBN (ön-eğitim)	Denetimsiz aşama etiket ihtiyacını azaltır
Sıralı görüntü (video)	ConvLSTM	Uzamsal + zamansal özellikler birlikte
Veri miktarı < 25.000	Klasik ML önce dene	DL güvenilir sonuç vermeyebilir

12. Referanslar & Ek Kaynaklar

Temel Atıf

Emmert-Streib F., Yang Z., Feng H., Tripathi S. & Dehmer M. (2020). An Introductory Review of Deep Learning for Prediction Models With Big Data. Frontiers in Artificial Intelligence, 3, 4. doi: 10.3389/frai.2020.00004

Öne Çıkan Referanslar

Referans	Katkısı
LeCun, Bengio & Hinton (2015) — Nature	Deep Learning genel bakış — alan rehberi
Hinton et al. (2006) — Neural Computation	DBN ve greedy layer-wise ön-eğitim
Hochreiter & Schmidhuber (1997)	LSTM'nin orijinal tanıtımı
He et al. (2016) — CVPR	ResNet — artık öğrenme
Goodfellow et al. (2014) — NIPS	Generative Adversarial Networks
Krizhevsky et al. (2012) — NIPS	AlexNet — CNN rönesansının başlangıcı
Goodfellow, Bengio & Courville (2016)	Deep Learning — kapsamlı ders kitabı

Yazılım Kütüphaneleri

Kütüphane	Dil	Desteklenen Modeller
TensorFlow / Keras	Python & R	Tüm modeller — en yaygın kullanım
PyTorch	Python	Araştırma odaklı — dinamik hesaplama grafiği
scikit-learn	Python	MLP dahil klasik ML modelleri

h2o	R & Python	CNN, DBN, MLP — büyük veri odaklı
fastai	Python	CNN — PyTorch üzerine inşa edilmiş yüksek seviye API

Bu sunum, Emmert-Streib et al. (2020) makalesinin ayrıntılı bir özetidir.